

## Guiding Principle

脳は自分自身への feedback をもっている。

もしもこの値処理を考へなければ、ネットワーク行列  $W$  と、各ニューロンの  
発火状態  $x$  を使って、 $y = W \cdot x$  によるネットワークの 1 step の処理。

これは自己 feedback 状態を望み、 $W^{(n)} x$  という  
形になった。記憶は  $x$  の中で残った状態として理解出来る。

$$W = \begin{pmatrix} 0 & w_{12} & w_{13} & \dots \\ w_{21} & 0 & & \\ \vdots & & \ddots & \end{pmatrix}$$

対角項 = 0, 必ずしも対称性は要求しない。

Q.  $W$  の形はどのような形が良い?

これは全行フルに決めて。

$$L^2 = \sum_s [x^s - W \cdot x^s]^2$$

を最小化するとき、 $W$  を求めた。

(この定義は  $n$  によって成立した。研究は必要。

ただし、微分を行う上では、規格化も行う必要がある。理想的。

$L = \sum_s x^s \cdot (W \cdot x^s)$  は、双対的、最小が存在しない)

$$\mathcal{L}^2 = \sum_s \left[ |W X^s|^2 - 2 \cdot W \cdot X^s + |X^s|^2 \right]$$

$$\begin{aligned} \frac{\partial \mathcal{L}^2}{\partial w_{pz}} &= \frac{\partial}{\partial w_{pz}} \sum_s \left\{ \sum_i \left( \sum_j w_{ij} X_j^s \right) \cdot \left( \sum_k w_{ik} X_k^s \right) - 2 \cdot \sum_{ij} w_{ij} X_i^s X_j^s \right\} \\ &= \sum_s \left\{ 2 \cdot \sum_i \delta_{ip} X_i^s \sum_k w_{ik} X_k^s - 2 \cdot X_p^s X_z^s \right\} \\ &= 2 \cdot \sum_s \left( \sum_k w_{pk} X_k^s X_z^s - X_p^s X_z^s \right) \end{aligned}$$

$$\therefore \text{よ、 } S_{pz} \equiv \sum_s X_p^s X_z^s \quad \text{と置く。}$$

$$\frac{\partial \mathcal{L}^2}{\partial w_{pz}} = 2 \cdot [W \cdot S - S]_{pz}$$

これ加減しての  $p, z$  について、ゼロにしたいから、 $\mathcal{L}^2$  最小の条件、すなわち

$$W \cdot S = S \quad \left( S_{ij} \equiv \sum_s X_i^s X_j^s, \quad W \text{ は 対角線以外の非対称行列} \right)$$

を満たす  $W$  求、最も多くのニューラルネットワークを構築可能なように  
記憶していることに注意。

今回の  $\mathcal{L}^2$  の定義の下で

$W$  の求め方には 2つ ある。

### ①、厳密解.

→  $W_{ij}$  の各成分を変数として、 $W \cdot S = f$  の関係系元から  
連立一次方程式を作り、解けば良い。  
ただし、自由度を数えて。

$$(W - I) \cdot S = 0 \quad \dots \textcircled{1}$$

↓

自由度は、

$$N^2 - N$$

(対角項 = 0 より)

①式の移項

← もしくは、 $W$  が対称行列であったと仮定すれば、  
 $\frac{1}{2} N(N-1)$  個

これに対して、方程式は、①の  $N$  行分であり、 $N$  自由度。

よって、 $N$  ② では、 $W$  の自由度の方が大きくなり、  
そのため、ネットワークの言語で自由度が生じる。

②、ただし、ここを求めた  $W$  は、 $L^2$  を最小化して得られたものであり、  
個々のベクトル  $X^S$  に対し、 $X^S = W \cdot X^S$  を成立させているとは限らない。ことに注意。



②、発出を知り入れ、反復的に収束させた法。

今、発出ベクトル  $v$  を加えたとする。この時、 $(W-I)S=0$  に成り立つため、  
ために必要な変更量  $\Delta W$  を求めよう。  $(\Delta S)_{ij} \equiv v_i v_j$  とおく。

$$\begin{aligned} [(W + \Delta W) - I] \cdot (S + \Delta S) &= \underbrace{(W - I) \cdot S}_0 + \Delta W \cdot S + (W - I) \cdot \Delta S + \underbrace{\Delta W \cdot \Delta S}_{\text{4次}} \\ &= \Delta W \cdot S + (W - I) \cdot \Delta S = 0 \end{aligned}$$

よって、 $\Delta W = (I - W) \cdot \Delta S \cdot S^{-1}$ 。

さて、これを近似計算すれば、 $S$  (相関行列) は基本的に  
対角成分のみに加えられ、非対角成分は小さいことを使う。

対角成分を  $D$ 、非対角成分を  $A$  とおくと、

$$S = D + A.$$

この時、 $S^{-1}$  は、

$$I = S S^{-1} = (D + A) S^{-1}$$

$$D S^{-1} = I - A S^{-1}$$

$$S^{-1} = D^{-1} (I - A S^{-1})$$

$$= D^{-1} - D^{-1} A D^{-1} + \dots$$

と展開出来る。

第一項の4を計算して、

$$[\Delta W]_{ij} \sim [(I - W) \cdot \Delta S \cdot D^{-1}]_{ij} = \frac{1}{\sum_s (r_{js})^2} \left[ \underbrace{r_i r_j}_{\text{① 強化学習項}} - \underbrace{\sum_k W_{ik} r_k \cdot r_j}_{\text{②}} \right]$$

となり、強化学習の基本原理となっていることが分かった。

このモデルにおける学習の